

Feuille Cours / TD 2 - Algorithmes probabilistes Algorithmes QuickSelect et QuickSort

1 Problème de la sélection

Le problème de la sélection est le suivant : étant donné un tableau T d'entiers non triés de taille n (deux à deux distincts pour simplifier) et un entier k , on veut trouver le $k^{\text{ème}}$ plus petit élément de T , que l'on note $T_{(k)}$. Par exemple, $T_{(1)}$ est le plus petit élément de T .

Exercice 1.

1. Écrire un algorithme naïf pour résoudre ce problème. Quelle est sa complexité ?

Considérons l'algorithme suivant :

Algorithm 1: QUICKSELECT(T, k)

```

Entrée : un tableau  $T$  de  $n$  entiers non triés, un entier  $k$ 
Sortie : le  $k^{\text{ème}}$  plus petit élément de  $T$ 
 $i \leftarrow$  entier aléatoire entre 0 et  $n - 1$ 
 $B, H \leftarrow$  tableaux vides
for  $j = 0$  to  $n - 1$ ,  $j \neq i$  do
  if  $T[j] < T[i]$  then
     $\perp$  Ajouter  $T[j]$  à  $B$ 
  else
     $\perp$  Ajouter  $T[j]$  à  $H$ 
Si  $|B| = k - 1$  : renvoyer  $T[i]$ 
Si  $|B| > k - 1$  : renvoyer QUICKSELECT( $B, k$ )
Sinon : renvoyer QUICKSELECT( $H, k - |B| - 1$ )

```

Exercice 2.

On va tester l'algorithme sur le tableau $T = [8, 2, 5, 12, 7, 3, 22, 6, 15, 11, 1, 17, 19, 10]$ avec $k = 6$.

1. Appliquer l'algorithme au tableau T , en supposant que la variable $i = 4$. Que contiennent les tableaux B et H à la sortie de la première boucle ? Que renvoie l'algorithme ?
2. Appliquer à nouveau l'algorithme au tableau T , en supposant cette fois que la variable $i = 7$. Que contiennent les tableaux B et H à la sortie de la première boucle ? On continuera les appels récursifs avec $i = 5$ au premier appel, puis $i = 1$ au second, que renvoie l'algorithme ?

On veut maintenant montrer que l'algorithme est correct.

3. Montrer que l'algorithme renvoie bien le $k^{\text{ème}}$ plus petit élément de T .
4. Est-ce que l'algorithme peut se tromper ?
5. Quelle est la complexité de cet algorithme dans le pire des cas ?

On va maintenant montrer que dans le cas général, la complexité de l'algorithme est meilleure. En particulier, que l'espérance du nombre de comparaisons effectuées par l'algorithme QUICKSELECT(T, k) est bornée par $4n$.

Soit X_n la variable aléatoire qui compte le nombre de comparaisons effectuées au cours de l'algorithme pour un tableau T de taille n , on cherche à borner $\mathbb{E}[X_n]$. On rappelle que l'espérance d'une variable aléatoire discrète X est définie par $\mathbb{E}[X] = \sum_v v \times \Pr[X = v]$, il s'agit intuitivement de la moyenne pondérée des

valeurs de tous les événements possibles.

Pour montrer ce résultat par récurrence sur n , on voit que le cas $n = 1$ est trivial, puis on suppose que le résultat est vrai pour tout $m < n$.

En conditionnant X_n à la taille du tableau B après la boucle, l'espérance totale est :

$$\mathbb{E}[X_n] = \sum_{m=0}^{n-1} \Pr[|B| = m] \cdot \mathbb{E}[X_n \mid |B| = m]$$

6. Soit $m < n$, que vaut $\Pr[|B| = m]$ où $|B|$ est la taille du tableau après la boucle ?
7. On cherche maintenant à borner $\mathbb{E}[X_n \mid |B| = m]$:
 - Donnez une borne dans le cas où $m = k - 1$,
 - Donnez une borne dans le cas où $m < k - 1$, puis dans le cas où $m > k - 1$, en utilisant l'hypothèse de récurrence.
 - Pour avoir une borne générale qui ne dépend pas de k , on va supposer être dans le cas le plus défavorable à chaque fois. En déduire une borne sur $\mathbb{E}[X_n]$ et conclure la récurrence.

2 Algorithme de tri

On étudie maintenant l'algorithme de tri rapide, de type diviser-pour-régner. La méthode consiste à placer un élément du tableau (appelé pivot) à sa place définitive, en permutant tous les éléments de telle sorte que tous ceux qui sont inférieurs au pivot soient à sa gauche et que tous ceux qui sont supérieurs au pivot soient à sa droite. Cette opération s'appelle le partitionnement. Pour chacun des sous-tableaux, on définit un nouveau pivot et on répète l'opération de partitionnement. Ce processus est répété récursivement, jusqu'à ce que l'ensemble des éléments soit trié.

Algorithm 2: QUICKSORT(T)

Entrée : un tableau T de n entiers non triés

Sortie : le tableau T trié

Si $|T| = 1$, renvoyer T .

$i \leftarrow \text{CHOIXPIVOT}$

Partitionner T en deux sous tableau B et H tel que B contienne les éléments strictement inférieurs à $T[i]$ et H les éléments supérieurs à $T[i]$.

Renvoyer la concaténation de QUICKSORT(B), $T[i]$ et QUICKSORT(H).

Exercice 3.

On considère tout d'abord que le pivot i est choisi arbitrairement, par exemple en prenant le premier élément du tableau.

- Que vaut la complexité dans le pire des cas ?
- Dans le meilleur des cas, où à chaque étape les deux sous-tableau B et H sont de même taille, que vaut la complexité ?

L'objectif est maintenant d'étudier le cas d'un pivot aléatoire. L'indice i est donc choisi uniformément dans les indices du tableau.

Exercice 4.

1. Montrez que l'algorithme est correct.
2. Que vaut la complexité dans le pire des cas ?

On souhaite montrer que l'espérance du nombre de comparaison effectuées par $\text{QUICKSORT}(T)$ est $O(n \log n)$. On va calculer pour cela pour chaque couple d'éléments de T la probabilité qu'ils soient comparés au cours de l'algorithme.

Pour $1 \leq i \leq n$, $T_{(i)}$ est le i ème élément de T par ordre croissant, et pour $1 \leq i < j \leq n$ on appelle X_{ij} la variable aléatoire qui vaut 1 si $T_{(i)}$ est comparé à $T_{(j)}$ pendant l'algorithme est 0 sinon. Enfin, $X = \sum_{i < j} X_{ij}$. Notre objectif est de calculer $\mathbb{E}[X]$.

Exercice 5.

1. Soit $T = [8, 2, 5, 12, 7, 3, 22, 6]$, appliquez l'algorithme pour déterminer les valeurs des tableaux B et H à chaque étape et dans les récursions, pour le pivot $i = 4$, puis les pivots $i = 1$ et $i = 0$ dans les appels récursifs sur B , et $i = 1$ dans l'appel récursif sur H .
 — Donner la valeur de $T_{(i)}$ pour $i = 1$ et pour $1 < j \leq n$, les valeurs de X_{1j} .
 — Donner la valeur de $T_{(i)}$ pour $i = 6$, pour $6 < j \leq n$ les valeurs de X_{6j} , et pour $1 \leq i < 6$ les valeurs de X_{i6} .
2. Montrez que $\mathbb{E}[X] = \sum_{i < j} \Pr[X_{ij} = 1]$.
3. A quel moment de l'algorithme deux éléments $T_{(i)}$ et $T_{(j)}$ sont-ils comparés (en particulier à quelles conditions sur ces éléments)? Montrez que pour $1 \leq i < j \leq n$, $\Pr[X_{ij} = 1] = \frac{2}{j-i+1}$.
4. En utilisant le fait que $\sum_{k=1}^n 1/k = \ln(n) + O(1)$, en déduire que $\mathbb{E}[X] \leq O(n \log n)$.